

# Tarea de ayudantia compu-2

January 10, 2020

## 0.1 Ayudantía - Regresión Lineal


```
In [4]: import numpy as np
import scipy as scp
import matplotlib.pyplot as plt
%matplotlib inline
```

### 0.1.1 Generación de los datos

```
In [5]: X = [-2,-2,-1,0,1,2,2,3,4,5]
Y = [-4,-2,-3,-2,-2,-1,1,3,2,3]
```

```
In [6]: plt.plot(X,Y, '.k')
```

```
Out[6]: [<matplotlib.lines.Line2D at 0x114968fd0>]
```



## 0.1.2 Ajuste de un modelo lineal

```
In [7]: x_prom = np.mean(X)
        y_prom = np.mean(Y)
        x_var = np.var(X)
        covarianza = np.cov(X,Y, bias=True)[0][1] #Dividido por N
        print("Promedio X = ", x_prom)
        print("Promedio Y = ", y_prom)
        print("Varianza X = ", x_var)
        print("Covarianza = ", covarianza)
```

```
Promedio X = 1.2
Promedio Y = -0.5
Varianza X = 5.36
Covarianza = 5.1000000000000005
```

```
In [8]: beta_1 = covarianza/x_var
        beta_0 = y_prom-beta_1*x_prom
        print("Beta_0 =", beta_0, " Beta_1 = ",beta_1)
```


```
Beta_0 = -1.6417910447761195 Beta_1 = 0.9514925373134329
```

```
In [9]: y_pred = beta_1*np.array(X)+beta_0
```

```
In [10]: e_i = Y-y_pred # residuos
```

```
In [11]: plt.plot(X,Y, '.k')
         plt.plot(X,y_pred, '-b')
         plt.plot(X,y_pred, '*r')
```


```
Out[11]: [matplotlib.lines.Line2D at 0x114aa0110>]
```



### 0.1.3 Gráfico de los residuos

```
In [12]: plt.bar(range(10),e_i) # Gráfico de los residuos
```

```
Out[12]: <BarContainer object of 10 artists>
```



```
In [13]: rho=np.corrcoef(X,Y)[0][1] # coeficiente de correlación  
print("Coeficiente de correlación de Pearson = ",rho)
```

```
Coeficiente de correlación de Pearson = 0.9107723725393417
```

## 0.2 Regresión lineal usando STATMODELS

<https://www.statsmodels.org/stable/index.html>

```
In [14]: import statsmodels.api as sm
```

```
In [15]: X = sm.add_constant(X)
```

```
In [16]: modelo_lineal = sm.OLS(Y,X).fit()
```

```
In [17]: modelo_lineal.summary()
```

```
/Users/constanzapardo/opt/anaconda3/lib/python3.7/site-packages/scipy/stats/stats.py:1450: UserWarning:
  "anyway, n=%i" % int(n))
```

```
Out[17]: <class 'statsmodels.iolib.summary.Summary'>
```


```
"""
                                OLS Regression Results
=====
Dep. Variable:                  y      R-squared:                0.830
Model:                            OLS      Adj. R-squared:           0.808
Method:                 Least Squares      F-statistic:                38.92
Date:                Thu, 09 Jan 2020      Prob (F-statistic):          0.000249
Time:                        19:31:00      Log-Likelihood:             -14.176
No. Observations:                  10      AIC:                        32.35
Df Residuals:                      8      BIC:                        32.96
Df Model:                          1
Covariance Type:                nonrobust
=====
                    coef    std err          t      P>|t|      [0.025     0.975]
-----
const            -1.6418     0.398     -4.128     0.003     -2.559     -0.725
x1               0.9515     0.153     6.239     0.000      0.600      1.303
=====
Omnibus:                 0.942    Durbin-Watson:           1.767
Prob(Omnibus):           0.624    Jarque-Bera (JB):         0.753
Skew:                    0.535    Prob(JB):                 0.686
Kurtosis:                2.187    Cond. No.                  3.04
=====

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly spec.
"""
```

### 0.3 Ejemplo 2

```
In [18]: n_obs = 100
X = np.random.random((n_obs,2))
X = sm.add_constant(X)
beta = [1, 0.1, 0.5]
e = np.random.randn(n_obs)*0.1
Y = np.dot(X,beta) + e
plt.subplot(211)
plt.plot(X[:,1],Y,'.k',alpha=0.5)
plt.subplot(212)
plt.plot(X[:,2],Y,'.b',alpha=0.5)
```

```
Out[18]: [<matplotlib.lines.Line2D at 0x1c1d0fad10>]
```



```
In [19]: modelo = sm.OLS(Y,X)
         modelo = modelo.fit()
```

```
In [20]: modelo.summary()
```

```
Out[20]: <class 'statsmodels.iolib.summary.Summary'>
        """
```

```

                                OLS Regression Results
=====
Dep. Variable:                  y      R-squared:                0.668
Model:                            OLS      Adj. R-squared:         0.661
Method:                 Least Squares      F-statistic:            97.41
Date:                Thu, 09 Jan 2020      Prob (F-statistic):      6.32e-24
Time:                  19:32:28      Log-Likelihood:         83.238
No. Observations:                100      AIC:                   -160.5
Df Residuals:                     97      BIC:                   -152.7
Df Model:                           2
Covariance Type:                nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	1.0138	0.031	32.667	0.000	0.952	1.075
x1	0.0238	0.040	0.600	0.550	-0.055	0.103
x2	0.5410	0.039	13.850	0.000	0.463	0.619

```

=====
Omnibus:                        0.417      Durbin-Watson:           1.886

```

Prob(Omnibus):	0.812	Jarque-Bera (JB):	0.248
Skew:	0.121	Prob(JB):	0.883
Kurtosis:	3.025	Cond. No.	5.93

=====

Warnings:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

In [21]: modelo.params

Out[21]: array([1.01381804, 0.02383884, 0.54100075])

In [22]: print("R2 (coef determinacion) = ", modelo.rsquared)  
print("Correlacion Pearson = ", np.sqrt(modelo.rsquared))

R2 (coef determinacion) = 0.6675950278510947

Correlacion Pearson = 0.8170648859491483

In [ ]:

## 0.4 Descripción de la Tarea

En este trabajo se espera que el estudiante realice un análisis de regresión con bases de datos. Deberá entregar el archivo Jupyter y un archivo pdf con las tablas resultantes con una discusión de los resultados.

Para realizar el estudio experimental deberá utilizar uno de los siguientes conjuntos de datos extraídos de la UCI Machine Learning Repository.

<https://archive.ics.uci.edu/ml/index.php>

Bank Marketing Data Set: <https://archive.ics.uci.edu/ml/datasets/Bank+Marketing>

Student Performance Data Set: <https://archive.ics.uci.edu/ml/datasets/Student+Performance>

Census Income Data Set: <https://archive.ics.uci.edu/ml/datasets/Census+Income>

Heart Disease Data Set: <https://archive.ics.uci.edu/ml/datasets/Heart+Disease>

Breast Cancer Wisconsin (Diagnostic) Data Set: <https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+W>

### 0.4.1 Para la presente tarea se deberá realizar:

1. Realizar un estudio de estadística descriptiva a dos variables numéricas. Hacer una tabla con los resultados.
2. Visualizar al menos 3 variables con los gráficos a elección
3. Tomar dos variables de interés y realizar una regresión lineal
4. De la regresión lineal, realizar un grafico y comentar los resultados.
5. Con variables numéricas, sacar promedio, varianza y covarianza.
6. Crear un dataframe con los datos.

#### 0.4.2 Consideraciones:

• Deberá entregar un informe utilizando Jupyter.

• Fecha y hora de entrega: 23/01/2020, 23:55 hrs utilizando la plataforma <https://classroom.google.com>

• Cada día de atraso será penalizado con 1 décima

• Se evaluará complejidad e interpretación de los datos

#### 0.4.3 Referencias

1. ScyPy.org, Statistical Functions (scipy.stats). <http://docs.scipy.org/doc/scipy/reference/stats.html>
2. Pandas, Python Data Analysis Library. <http://pandas.pydata.org/>
3. Seaborn, Seaborn: statistical data visualization. <https://stanford.edu/~mwaskom/software/seaborn/>
4. Numpy, Fundamental package for scientific computing with Python. <http://www.numpy.org/>
5. Matplotlib, Biblioteca gráfica para python. <http://matplotlib.org>
6. Scipy Lecture Notes. <http://www.scipy-lectures.org>
7. STATMODELS. <https://www.statsmodels.org/stable/index.html>